

Trabalho Computacional 2: Modelagem, Validação e Comparação de Modelos de Aprendizado de Máquina^{*}

Samir Angelo Milani Martins^{*}

^{*} Departamento de Engenharia Elétrica, Universidade Federal de São João del-Rei, MG (e-mail: martins@ufsj.edu.br).

Abstract: This document describes the second computational assignment of the course Machine Learning Applied to Engineering. The assignment requires each group to extend the real-data study developed in the first assignment by formulating a supervised learning problem, implementing at least three classification or regression models, validating them properly, and comparing their performance using quantitative metrics. The emphasis is on reproducibility, methodological rigor, critical interpretation, and engineering relevance.

Resumo: Este documento apresenta o enunciado do Trabalho Computacional 2 da disciplina Machine Learning aplicado à Engenharia. O trabalho exige que cada grupo dê continuidade ao estudo com dados reais desenvolvido no Trabalho 1, formulando um problema de aprendizado supervisionado, implementando ao menos três modelos de classificação ou regressão, validando-os de forma adequada e comparando seus resultados por meio de métricas quantitativas. O foco do trabalho está na reprodutibilidade, no rigor metodológico, na interpretação crítica e na relevância dos resultados para problemas de Engenharia.

Keywords: Machine Learning; classification; regression; model validation; engineering applications.

Palavras-chaves: Aprendizado de máquina; classificação; regressão; validação de modelos; aplicações em engenharia.

1. INTRODUÇÃO

O Trabalho Computacional 1 (T1) teve como objetivo consolidar os conteúdos iniciais da disciplina, incluindo Python, leitura e organização de bases reais, análise exploratória de dados, estatística descritiva, visualização, correlação, probabilidade e discussão conceitual sobre aprendizado de máquina. Nele, os alunos desenvolveram afinidades com ferramentas como: i) gestão de ambientes conda; ii) uso de GitHub; iii) instalação e gestão de bibliotecas.

O Trabalho Computacional 2 (T2) dá continuidade direta a esse processo. Cada grupo deverá utilizar o problema, a base de dados, as análises ou as conclusões obtidas no T1 como ponto de partida para construir uma aplicação supervisionada de aprendizado de máquina. O grupo deverá formular um problema de classificação ou de regressão, implementar ao menos três modelos distintos, validar os resultados de forma tecnicamente adequada e discutir criticamente o desempenho obtido. Os modelos deverão ser comparados quantitativamente, por meio de um mínimo de três métricas distintas.

Este trabalho corresponde à etapa de implementação e comparação de técnicas de aprendizado de máquina, com ênfase nos tópicos de classificação, regressão, uso de bibliotecas

como **Scikit-Learn** e **SysIdentPy**, além da interpretação dos resultados em contexto de Engenharia.

2. OBJETIVOS

O objetivo geral do T2 é desenvolver um estudo computacional completo de aprendizado supervisionado a partir dos dados e resultados obtidos no T1.

São objetivos específicos:

- formular um problema de classificação ou regressão a partir do tema estudado no T1;
- definir claramente variáveis de entrada, variável alvo e hipótese de modelagem;
- preparar os dados para modelagem, incluindo tratamento, transformação e separação adequada dos conjuntos de treino e teste (ou treino, validação e teste);
- implementar pelo menos três modelos diferentes de aprendizado de máquina;
- avaliar os modelos por meio de métricas adequadas ao tipo de problema;
- comparar quantitativa e qualitativamente os resultados obtidos;
- discutir sobreajuste, subajuste, viés, variância, limitações dos dados e aplicabilidade em Engenharia;
- produzir um artigo técnico no formato deste template.

^{*} Disciplina Machine Learning aplicado à Engenharia, Curso de Engenharia Elétrica, Universidade Federal de São João del-Rei.

3. DEFINIÇÃO DO PROBLEMA

Cada grupo deverá escolher uma formulação de aprendizado supervisionado associada ao próprio T1. A escolha entre classificação e regressão é livre, desde que seja tecnicamente justificada.

O grupo deverá explicitar:

- qual é o problema escolhido;
- por que ele é relevante;
- qual é a variável alvo;
- quais variáveis serão usadas como entradas, e por quais razões foram escolhidas;
- se o problema é de classificação ou regressão;
- quais limitações da base podem afetar a modelagem.

Não será aceito um T2 desconectado do T1, exceto mediante justificativa formal e aprovação prévia do professor.

4. DADOS E PRÉ-PROCESSAMENTO

O conjunto de dados utilizado no T2 deverá ser derivado da base analisada no T1. O grupo poderá complementar, reorganizar ou corrigir os dados, desde que documente claramente todas as alterações.

O artigo e o notebook deverão conter:

- descrição da origem da base de dados;
- resumo das principais conclusões do T1 que motivaram o T2;
- descrição das variáveis utilizadas;
- tratamento de valores ausentes, inconsistentes ou duplicados;
- transformação de variáveis, normalização, padronização ou codificação, quando necessário;
- separação entre variáveis de entrada e variável alvo;
- análise sobre possível desbalanceamento de classes, quando o problema for de classificação.

5. DIVISÃO DOS DADOS

O grupo deverá dividir os dados de forma compatível com o problema. A estratégia adotada deve ser justificada no artigo.

Para bases sem dependência temporal explícita, recomenda-se reservar um mínimo de 30% dos dados para teste, preferencialmente com validação cruzada no conjunto de treinamento.

Para séries temporais, a divisão deve respeitar a ordem cronológica dos dados. Nesse caso, o grupo não deve embaralhar amostras de forma que informações futuras sejam usadas para prever o passado. Recomenda-se separar os dados mais antigos para treinamento e os mais recentes para teste.

Em problemas de classificação com classes desbalanceadas, a divisão deve preservar, sempre que possível, a proporção entre classes.

6. MODELOS OBRIGATÓRIOS

Cada grupo deverá implementar e comparar pelo menos três modelos distintos. Os modelos devem ser adequados ao tipo de problema escolhido.

Para problemas de classificação, são exemplos:

- K-Nearest Neighbors;
- regressão logística;
- Support Vector Machine;
- árvore de decisão;
- floresta aleatória;
- gradient boosting ou métodos similares.

Para problemas de regressão, são exemplos:

- regressão linear;
- regressão Ridge ou Lasso;
- K-Nearest Neighbors Regressor;
- Support Vector Regression;
- árvore de regressão;
- floresta aleatória para regressão;
- modelos de identificação de sistemas com SysIdentPy, quando pertinente.

O uso de modelos mais avançados é permitido, mas não substitui a necessidade de explicar adequadamente a metodologia, os parâmetros escolhidos e as limitações do modelo. O objetivo principal é comparar modelos de forma correta e **interpretar os resultados com maturidade técnica**.

7. MÉTRICAS DE AVALIAÇÃO

As métricas devem ser escolhidas de acordo com o tipo de problema.

7.1 Classificação

Para problemas de classificação, o grupo poderá apresentar:

- matriz de confusão;
- acurácia;
- precisão;
- *recall*;
- F1-score;
- ROC-AUC ou outras métricas.

Em problemas com classes desbalanceadas, o grupo deverá discutir por que a acurácia isoladamente pode ser insuficiente.

7.2 Regressão

Para problemas de regressão, o grupo poderá apresentar:

- erro médio absoluto (MAE);
- erro quadrático médio (MSE) ou raiz do erro quadrático médio (RMSE);
- coeficiente de determinação (R^2);
- gráfico de valores preditos versus valores reais;
- análise gráfica de resíduos;
- análise de correlação e auto-correlação de resíduos;
- outras métricas.

Os erros devem ser interpretados na unidade física do problema sempre que possível. Por exemplo, erros em potência, tensão, preço, temperatura, glicose, demanda ou outra variável devem ser discutidos em termos práticos.

8. RESULTADOS ESPERADOS

O artigo deverá apresentar uma comparação clara entre os modelos. Recomenda-se incluir uma tabela com as métricas principais, conforme o tipo de problema. Um exemplo genérico é apresentado na Tabela 1.

Tabela 1. Exemplo de tabela comparativa de modelos.

Modelo	Métrica 1	Métrica 2	Métrica 3
Modelo A	–	–	–
Modelo B	–	–	–
Modelo C	–	–	–

Além da tabela, o grupo deverá apresentar gráficos que ajudem a interpretar os resultados. São exemplos:

- matriz de confusão;
- curva ROC ou curva precisão-revoção;
- gráfico de barras comparando métricas;
- gráfico de predição versus valor real;
- gráfico de resíduos;
- importância de variáveis;
- curvas de aprendizado;
- comparação temporal entre valor real e valor estimado.

Todos os gráficos devem ter título, legenda, eixos identificados e interpretação no texto. Gráficos sem análise não serão considerados evidência suficiente.

Discussões são obrigatórias e **devem ir além da apresentação de números**. O grupo deverá analisar:

- qual modelo apresentou melhor desempenho e por quê;
- se há sinais de sobreajuste ou subajuste;
- como o dilema viés-variância aparece no problema;
- como o pré-processamento influenciou os resultados;
- quais variáveis parecem mais relevantes;
- quais limitações da base de dados afetam a confiabilidade do modelo;
- se os resultados são coerentes com o fenômeno físico, elétrico, clínico, energético ou operacional estudado;
- quais cuidados seriam necessários para usar o modelo em uma aplicação real.

IMPORTANTE: quando o desempenho for baixo, o grupo não deve esconder o resultado. Deve discutir tecnicamente possíveis causas, como base pequena, ruído, variáveis pouco informativas, classes desbalanceadas, má formulação da variável alvo ou limitações dos modelos testados.

9. ESTRUTURA DO ARTIGO

O relatório final deverá ser entregue em formato de artigo científico, usando este template em duas colunas. A estrutura recomendada é:

- (1) Introdução;
- (2) Conceitos Preliminares;
- (3) Metodologia;
- (4) Resultados;
- (5) Conclusões;
- (6) Referências Bibliográficas.

O artigo deve ter entre 10 e 15 referências bibliográficas, das quais ao menos 5 devem ser artigos científicos publicados a partir de 2024. Deve ter, ainda, entre 6 a 8 páginas, contendo figuras, imagens e tabelas comparativas. Seção de agradecimentos é opcional. Figuras e tabelas devem ser numeradas e citadas no texto.

Trabalhos excepcionalmente bem executados, com contribuição original, boa qualidade técnica, autorização de todos os autores e aprovação do professor, poderão ser posteriormente adaptados para submissão a repositórios científicos, revistas ou eventos acadêmicos.

10. COMO CITAR REFERÊNCIAS

As referências bibliográficas devem ser inseridas no arquivo `.bib` do projeto e citadas ao longo do texto usando os comandos do $\text{\LaTeX}$. Não basta listar referências ao final do artigo: toda referência incluída deve ser efetivamente citada em algum ponto do texto.

Para citar uma referência como parte da frase, em que o autor é sujeito, use `\cite{chave}`. Por exemplo:

Segundo `\cite{pedregosa2011}`, ...

Para citar uma referência entre parênteses, use `\citep{chave}`. Por exemplo:

O Scikit-Learn é amplamente utilizado em aprendizado de máquina `\citep{pedregosa2011}`.

A chave da referência é o identificador definido no arquivo `.bib`. Um exemplo de entrada bibliográfica é:

```
@article{pedregosa2011,
  author = {Pedregosa, Fabian and others},
  title = {Scikit-learn: Machine Learning in Python},
  journal = {Journal of Machine Learning Research},
  volume = {12},
  pages = {2825--2830},
  year = {2011}
}
```

As referências devem priorizar artigos científicos. Páginas de internet, blogs, vídeos e materiais informais devem ser evitados. Bases de dados também devem ser citadas, indicando a fonte original, autores ou instituição responsável, ano e link de acesso, quando disponível.

Ao final do trabalho, o grupo deve verificar se todas as citações aparecem corretamente no PDF e se não há referências sem uso, citações quebradas ou campos bibliográficos incompletos.

11. NOTEBOOK E REPRODUTIBILIDADE

Além do artigo, o grupo deverá entregar um notebook `.ipynb` organizado, contendo todo o fluxo computacional do trabalho em forma sequencial. O notebook deverá permitir que o professor compreenda e reproduza os resultados.

IMPORTANTE: os grupos deverão construir o notebook do zero, e não a partir do Notebook entregue em T1. Códigos que foram criados para o T1 poderão ser reaproveitados, caso o grupo necessite.

O notebook deverá conter:

- identificação do grupo;
- link do repositório GitHub para T2;
- descrição da base;
- carregamento dos dados;
- pré-processamento;
- divisão dos dados;
- treinamento dos modelos;
- cálculo das métricas;
- geração das figuras usadas no artigo;
- breves comentários em Markdown explicando as decisões tomadas.

O grupo deverá entregar também um arquivo `environment.yml` (ambiente conda usado). O repositório deve conter os dados utilizados ou instruções claras para obtê-los, respeitando eventuais restrições de tamanho, licença ou privacidade.

12. USO DE INTELIGÊNCIA ARTIFICIAL

O uso de ferramentas de inteligência artificial generativa é permitido como apoio, desde que seja feito de forma ética e transparente, **e que o grupo saiba exatamente o que está fazendo, como as técnicas funcionam e saibam analisar os resultados obtidos**. O grupo continua responsável por todo o conteúdo entregue, incluindo código, interpretação, resultados, citações e conclusões. Serão penalizadas respostas genéricas, código não compreendido pelo grupo ou textos sem relação direta com os dados analisados.

13. INFORMAÇÕES ADICIONAIS

Data de entrega: 02/07/2026, via Campus Virtual.

Apresentações: a partir do dia 03/07. Cada grupo terá **20 minutos** para apresentar o trabalho, seguida de discussões. A apresentação deve focar no problema, metodologia, modelos, resultados e discussão crítica.

14. CONCLUSÃO

O T2 deve demonstrar que o grupo é capaz de transformar uma análise exploratória inicial em um estudo de aprendizado de máquina supervisionado. Espera-se que o trabalho apresente uma formulação clara do problema, implemente modelos adequados, compare resultados de forma justa e interprete criticamente as conclusões no contexto de Engenharia.

O resultado final não deve ser apenas um conjunto de códigos ou métricas. Deve ser um estudo técnico coerente, reproduzível e bem justificado, capaz de mostrar as possibilidades e limitações do uso de Machine Learning em dados reais.

AGRADECIMENTOS

Esta seção é opcional no artigo dos grupos. Caso seja usada, deve registrar apoios técnicos, bases de dados, laboratórios, equipes ou pessoas que contribuíram para a realização do trabalho.

REFERÊNCIAS

- Géron, A. (2020). *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras e TensorFlow*. Alta Books, Rio de Janeiro, 2 edition.
- Grus, J. (2020). *Data Science do Zero: Noções Fundamentais com Python*. Alta Books, Rio de Janeiro, 2 edition.
- Lacerda, W.R., da Andrade, L.P.C., Oliveira, S.C.P., and Martins, S.A.M. (2020). Sysidentpy: A python package for system identification using narmax models. *Journal of Open Source Software*, 5(54), 2384. doi:10.21105/joss.02384. URL <https://doi.org/10.21105/joss.02384>.
- Müller, A.C. and Guido, S. (2016). *Introduction to Machine Learning with Python: A Guide for Data Scientists*. O'Reilly Media, Sebastopol.
- Nielsen, A. (2021). *Análise Prática de Séries Temporais: Predição com Estatística e Aprendizado de Máquina*. Alta Books, Rio de Janeiro.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12, 2825–2830.